APRENDIZAJE NO SUPERVISADO

PRESENTADO POR MyA

Asignatura: Inteligencia Artificial
Docente: Hugo Espetia Huamanga
MyA:

- Jean Carlos Huanca Pilares
- Jamil Zamata Sotec
- Del Castillo Molina Gino Galois
- Sebastian Rodrigo Anaya Rodriguez
- Zavaleta Handa Fernando Hiroshi

CLUSTERING

-DBScan-

DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

DBSCAN es un algoritmo de agrupamiento basado en densidad, que identifica clusters en grandes conjuntos de datos según la densidad de puntos en el espacio. A diferencia de otros métodos de Clustering (como K-means), no necesita que se especifique el número de clusters con anticipación.

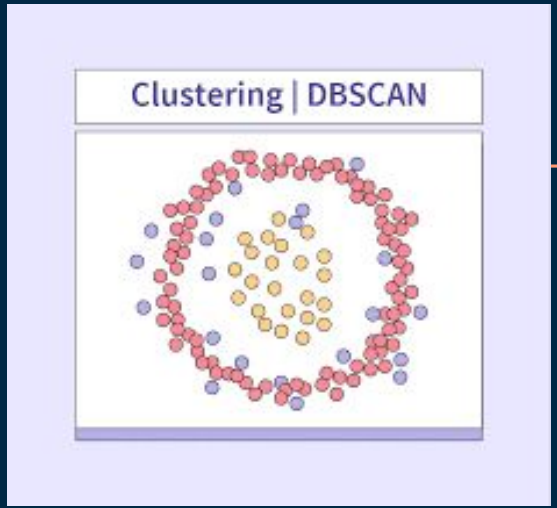

- Epsilon (ε): Radio que define una región alrededor de cada punto. Si otros puntos están dentro de este radio, se consideran vecinos.
- MinPts: Número mínimo de puntos que debe tener una región para considerarse un cluster.

- Core Points: Puntos que tienen al menos MinPts vecinos dentro de su radio ε.
- Border Points: Puntos que están dentro del radio ε de un punto core pero que tienen menos de MinPts vecinos.
- Noise Points: Puntos que no pertenecen a ningún cluster (no son puntos core ni border).

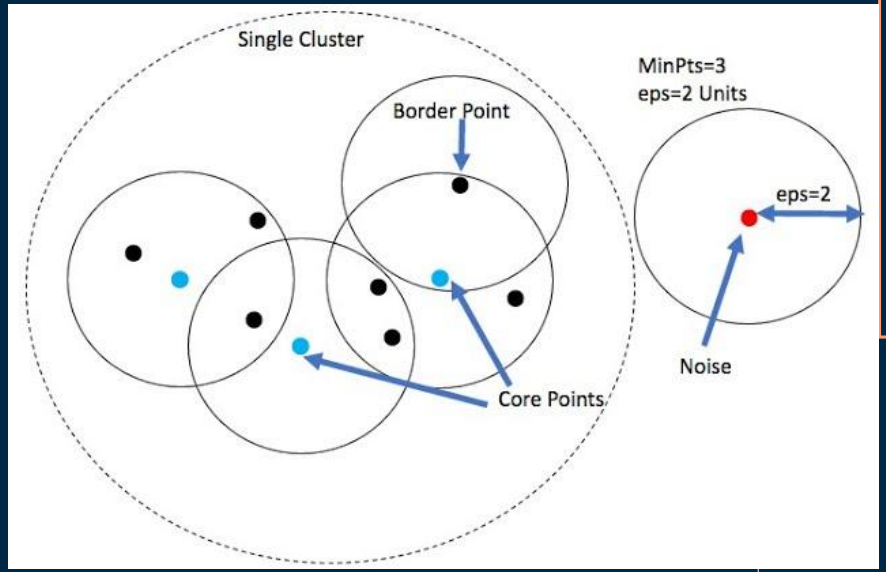

Características clave:

- Identificación de ruido: DBSCAN marca los puntos que no encajan bien en ningún cluster como ruido, permitiendo una mejor identificación de patrones.
- Clusters de forma arbitraria: Es eficaz para detectar clusters de cualquier forma, ya que se basa en la densidad de puntos.
- No requiere especificar el número de clusters. A diferencia de K-means, el número de clusters se deriva del parámetro ε.

Ventajas

- Flexibilidad en formas de clusters: DBSCAN detecta clusters de formas arbitrarias, como clusters no esféricos o con distribuciones complejas.
- Detección automática de ruido.
- No requiere predefinir el número de clusters.

Desventajas

- Elección sensible de parámetros: Elegir un valor inapropiado para ε o MinPts puede afectar significativamente el rendimiento del algoritmo.
- Problemas en datos de alta dimensión: En espacios de alta dimensión, puede ser difícil
- encontrar una buena distancia ε debido a la "maldición de la dimensionalidad."

IMPLEMENTACION

- Base de datos de departamentos en cusco .csv

- Importar pandas y librerías de clustering

- Cargar archivos

```
Precio,Locacion,Aream2,NroDormitorios,NroBanos,NroPisos,Zona
289311,San Sebastian,125,2,1,6,Urbanizacion
529492,San Jeronimo,150,2,1,6,Urbanizacion
529820,Saylla,111,2,1,1,Institucion
```

```
# Instalar scikit-learn si no lo tienes instalado
!pip install -U scikit-learn

# Importar las librerías necesarias
import pandas as pd
import numpy as np
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import DBSCAN
import matplotlib.pyplot as plt
import seaborn as sns
```

```
df = pd.read_csv("datos_casas_cusco.csv")
print(df.head())
```

```
   Precio       Locacion  Aream2  NroDormitorios  NroBanos  NroPisos  \
0  289311  San Sebastian     125               2         1         6
1  529492   San Jeronimo     150               2         1         6
2  529820         Saylla     111               2         1         1
3  612894       Santiago     249               3         3         8
4  778810        Wanchaq     242               5         5         3

             Zona
0     Urbanizacion
1     Urbanizacion
2      Institucion
```

- Normalización de datos

```python
# Seleccionar las columnas relevantes para el clustering
columnas_relevantes = ['Precio', 'Aream2', 'NroDormitorios', 'NroBanos', 'NroPisos']
datos = df[columnas_relevantes]

# Normalizar los datos para que tengan media 0 y varianza 1
scaler = StandardScaler()
datos_normalizados = scaler.fit_transform(datos)

# Mostrar un resumen de los datos normalizados
print("Datos normalizados:\n", datos_normalizados[:5])
```

```
Datos normalizados:
 [[-1.34612217 -0.39489029 -1.34232    -1.43231906  0.36498958]
 [-0.65314851 -0.01691804 -1.34232    -1.43231906  0.36498958]
 [-0.65220216 -0.60655476 -1.34232    -1.43231906 -1.53106019]
 [-0.41251587  1.47985209 -0.45248241 -0.01942726  1.12340949]
```

- Aplicar DBSCAN para la generación de clusters

```python
# Configurar y aplicar DBSCAN
dbscan = DBSCAN(eps=0.85, min_samples=5)  # Ajusta estos parámetros según sea necesario
etiquetas = dbscan.fit_predict(datos_normalizados)

# Agregar las etiquetas de los clusters al DataFrame original
df['Cluster'] = etiquetas

# Ver cuántos clusters se han encontrado (ignora el ruido, que es -1)
n_clusters = len(set(etiquetas)) - (1 if -1 in etiquetas else 0)
print(f"Número de clusters encontrados: {n_clusters}")
print(df['Cluster'].value_counts())
```

```
Número de clusters encontrados: 6
Cluster
 2    506
 0    486
 3    482
 1    469
-1     51
 5      3
 4      3
Name: count, dtype: int64
```

- Generacion de graficos

```python
from sklearn.decomposition import PCA

# Reducir la dimensionalidad a 2D usando PCA para visualización
pca = PCA(n_components=2)
datos_reducidos = pca.fit_transform(datos_normalizados)

# Crear un scatter plot de los clusters
plt.figure(figsize=(10, 8))
sns.scatterplot(x=datos_reducidos[:, 0], y=datos_reducidos[:, 1], hue=df['Cluster'], palette='viridis', s=60)
plt.title('Clusters de Casas en Cusco usando DBSCAN')
plt.xlabel('Componente principal 1')
plt.ylabel('Componente principal 2')
plt.legend(title='Cluster')
plt.show()
```

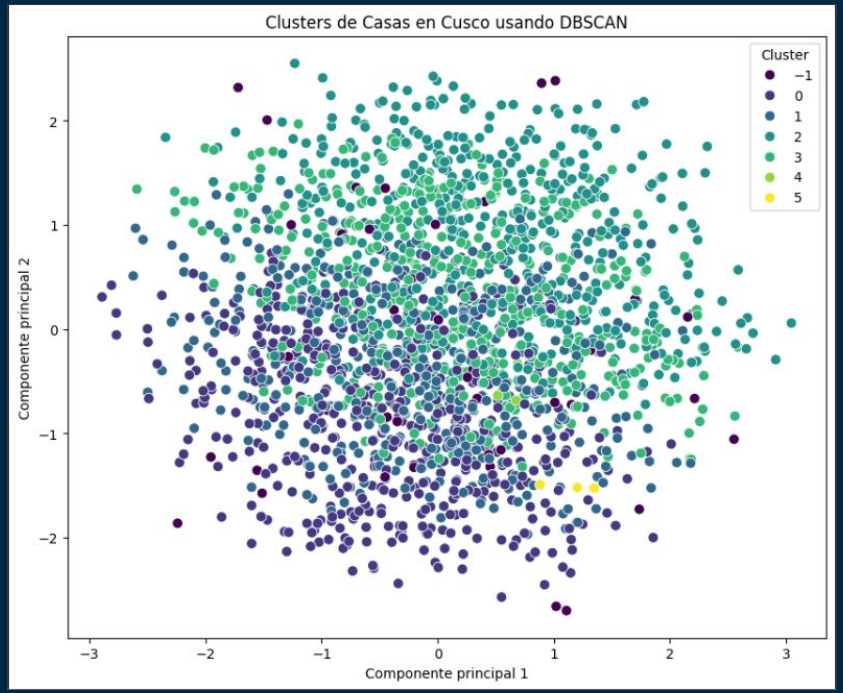

- Estadísticas descriptivas por cluster

```python
# Estadísticas descriptivas por cluster
estadisticas_clusters = df.groupby('Cluster')[columnas_relevantes].mean()
print("Estadísticas descriptivas por cluster:\n", estadisticas_clusters)
```

```
Estadísticas descriptivas por cluster:
                Precio      Aream2  NroDormitorios  NroBanos  NroPisos
Cluster
-1       7.776413e+05  174.843137        3.058824  2.941176  5.529412
 0       7.522917e+05  151.473251        2.000000  2.960905  5.043210
 1       7.326469e+05  143.978678        3.000000  3.095949  4.735608
 2       7.622094e+05  153.345850        5.000000  3.059289  5.164032
 3       7.743269e+05  153.109959        4.000000  2.979253  5.188797
 4       1.140024e+06   52.333333        4.000000  5.000000  1.333333
 5       1.770490e+05  210.000000        4.000000  5.000000  1.000000
```

https://colab.research.google.com/drive/1klu7o5uJOm11qG_HoLU88HRK3J3BySgw?usp=sharing#scrollTo=_jfc-hieNZAu

ASOCIACIÓN

-FP-

FP-Growth

Los algoritmos de reglas de asociación, como FP-Growth, son técnicas que buscan descubrir relaciones interesantes entre variables en grandes bases de datos. Son especialmente útiles para análisis de transacciones, como en supermercados, donde se
busca encontrar qué productos suelen comprarse juntos

FP-Growth Construye una estructura de árbol compacta (FP-tree) para evitar el recuento reiterado de itemsets frecuentes, mejorando la eficiencia en grandes bases de datos.

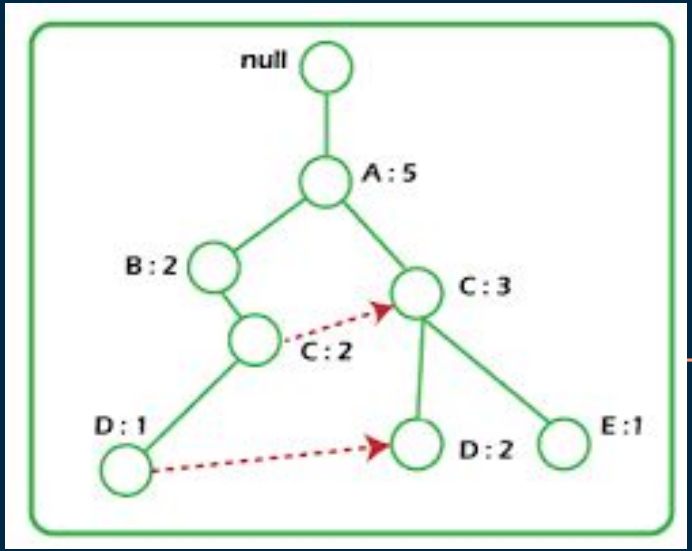

Características clave:

- Análisis exploratorio de grandes bases de datos: Proporciona reglas que pueden ayudar a comprender mejor los patrones ocultos.

- Eficiencia en bases de datos grandes: FP-Growth es más eficiente manejando grandes bases de datos.

Ventajas

- Mejora la eficiencia en bases de datos grandes, ya que evita la generación innecesaria de conjuntos de ítems

Desventajas

- Aunque más rápido, su implementación es más compleja y requiere más memoria.

IMPLEMENTACION

- Base de datos de departamentos en cusco .csv
- Importar pandas y mixtend
- Cargar archivos

Precio,Locacion,Aream2,NroDormitorios,NroBanos,NroPisos,Zona
289311,San Sebastian,125,2,1,6,Urbanizacion
529492,San Jeronimo,150,2,1,6,Urbanizacion
529820,Saylla,111,2,1,1,Institucion

```
[2] import pandas as pd
    from mlxtend.frequent_patterns import fpgrowth, association_rules
```

```
# Cargar el archivo al DataFrame
df = pd.read_csv('/content/datos_casas_cusco.csv')

# Evaluar la estructura del DataFrame: mostrar primeras 5 filas
print(df.head())
```

```
Datos  datos_casas_cusco.csv  sample_data
   Precio       Locacion  Aream2  NroDormitorios  NroBanos  NroPisos  \
0  289311  San Sebastian     125               2         1         6
1  529492   San Jeronimo     150               2         1         6
```

- Convertir los datos a formato binario

```
[6]  # Convertir columnas categóricas (Locacion y Zona) a formato binario
     df_binarizado = pd.get_dummies(df[['Locacion', 'Zona']])

     # Opcional: Binarizar los datos numéricos en rangos específicos
     df_binarizado['Area_Grande'] = (df['Aream2'] > 150).astype(int)
     df_binarizado['Muchos_Dormitorios'] = (df['NroDormitorios'] >= 3).astype(int)

     # Visualizamos los primeros datos binarizados
     print(df_binarizado.head())
```

```
   Locacion_Cusco  Locacion_San Jeronimo  Locacion_San Sebastian  \
0           False                  False                    True
1           False                   True                   False
2           False                  False                   False
3           False                  False                   False
4           False                  False                   False

   Locacion_Santiago  Locacion_Saylla  Locacion_Wanchaq  Zona_Avenida  \
0              False            False             False         False
1              False            False             False         False
```

- Aplicar FP-Growth

```
[7]  from mlxtend.frequent_patterns import fpgrowth, association_rules

     # Ejecutar FP-Growth con soporte mínimo del 20% (0.2)
     patrones_frecuentes = fpgrowth(df_binarizado, min_support=0.2, use_colnames=True)

     # Mostrar los patrones frecuentes encontrados
     print(patrones_frecuentes)

     # Generar reglas de asociación con un umbral de confianza del 50%
     reglas = association_rules(patrones_frecuentes, metric="confidence", min_threshold=

     # Mostrar las reglas de asociación
     print(reglas)
```

```
   support                        itemsets
0   0.7485              (Muchos_Dormitorios)
1   0.4905                   (Area_Grande)
2   0.3675  (Area_Grande, Muchos_Dormitorios)
     antecedents           consequents  antecedent support  \
0  (Area_Grande)  (Muchos_Dormitorios)              0.4905

   consequent support  support  confidence      lift  leverage  conviction  \
0              0.7485   0.3675    0.749235  1.000983  0.000361    1.002933
```

- Generacion de graficos

```
# Generar un gráfico de barras de los soportes de los patrones frecuentes
plt.figure(figsize=(10, 6))
patrones_frecuentes.plot(kind='bar', x='itemsets', y='support', legend=False, ax=pl
plt.title('Patrones Frecuentes - Gráfico de Barras')
plt.xlabel('Conjuntos de Ítems')
plt.ylabel('Soporte')
plt.xticks(rotation=45, ha='right')
plt.show()
```

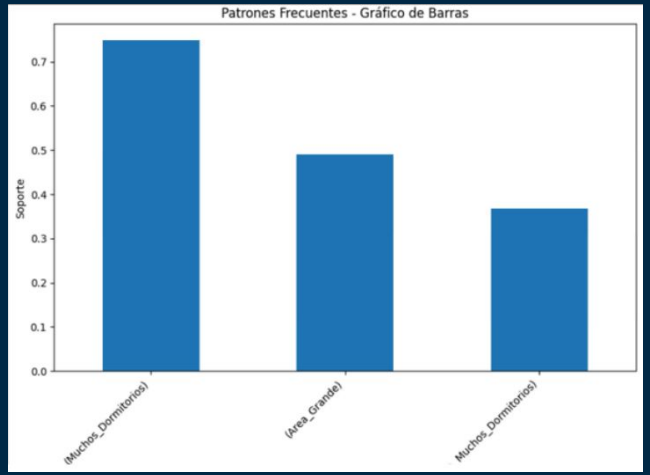

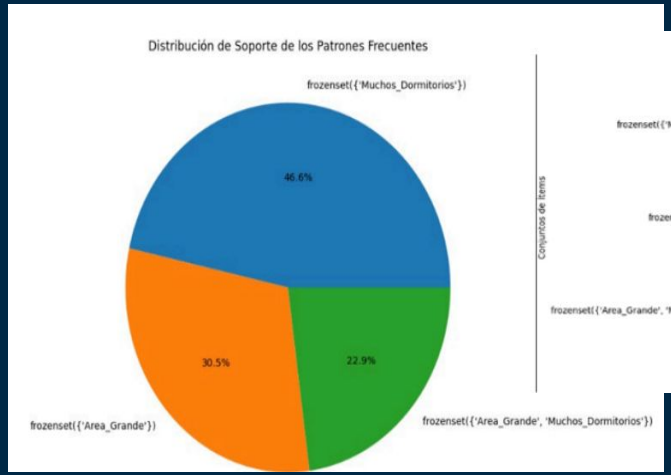

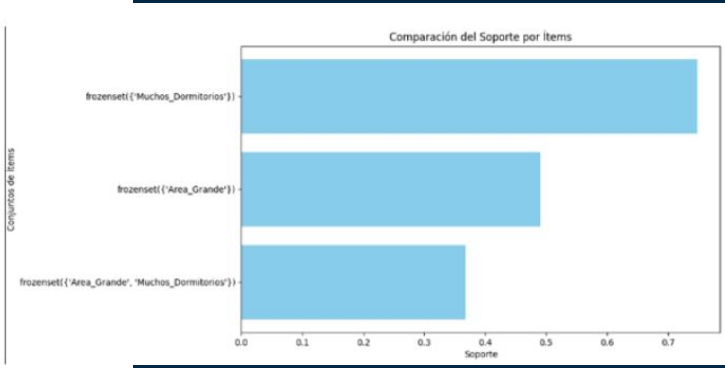

https://colab.research.google.com/drive/17wtMBh9FEaEoRRDy-50Fo7_oBXM8E__S?authu%20ser=1#scrollTo=6A3bUzwNF9a6

THANKS

Team : MyA